MEMORIA DEL PROYECTO

Evolución del rendimiento individual y colectivo en el Tour de Francia (2007–2026)

Proyecto individual · Data Science Bootcamp

Análisis exploratorio e inferencial de datos

Resumen ejecutivo

Este proyecto estudia la evolución del rendimiento individual y colectivo en el Tour de Francia masculino durante las ediciones comprendidas entre 2007 y 2026. La investigación utiliza datos históricos de corredores y etapas para examinar cinco dimensiones: velocidad media de los ganadores, diferencias de tiempo entre los primeros clasificados, distribución de las posiciones del Top 10 entre equipos, persistencia individual de los ciclistas y relación exploratoria entre edad y velocidad.

El trabajo se desarrolló en dos notebooks complementarios. El primero reúne la obtención, preparación, depuración, integración y exploración de los datos. El segundo desarrolla los contrastes inferenciales, interpreta los resultados y presenta la discusión, conclusiones, limitaciones y recomendaciones. La metodología combina estadística descriptiva, visualización y modelos estadísticos adecuados a la naturaleza de cada pregunta.

Entre los principales resultados, la velocidad media de los ganadores presenta una tendencia creciente estimada en 0,1675 km/h por año, estadísticamente significativa. Por el contrario, la comparación de las brechas temporales entre 2007–2016 y 2017–2026 no detecta diferencias significativas. La presencia de equipos en el Top 10 muestra una distribución desigual, tratada descriptivamente. En cuanto a la persistencia individual, el porcentaje de repetición es mayor entre quienes habían conseguido previamente un Top 10, aunque el modelo GEE no confirma una asociación estadísticamente significativa al 5 %. El análisis complementario tampoco encuentra una asociación significativa entre edad y velocidad individual.

1. Planteamiento del problema

El Tour de Francia constituye una competición de larga duración en la que el resultado final depende de múltiples componentes deportivos y contextuales. La clasificación general permite identificar al ganador, pero no describe por sí sola cómo cambia el rendimiento a lo largo del tiempo ni cómo se distribuyen los resultados entre los equipos y los corredores.

La velocidad media del ganador puede reflejar cambios en el ritmo global de la competición, aunque también está condicionada por la distancia, el desnivel, el trazado, la meteorología, las estrategias de carrera y los avances tecnológicos. De forma complementaria, las diferencias de tiempo entre los primeros clasificados permiten observar el grado de separación en la clasificación general. La recurrencia de equipos y ciclistas en el Top 10 aporta otra perspectiva: la concentración del éxito colectivo y la regularidad individual.

A partir de esta diversidad de indicadores, el proyecto plantea la pregunta: ¿cómo ha evolucionado el rendimiento individual y colectivo en el Tour de Francia entre 2007 y 2026? La finalidad no es reducir el rendimiento a una sola cifra, sino estudiar varias dimensiones y distinguir entre patrones descriptivos y resultados respaldados por evidencia estadística.

2. Objetivos e hipótesis

2.1 Objetivo general

Analizar la evolución del rendimiento individual y colectivo en el Tour de Francia durante el periodo 2007–2026, mediante indicadores de velocidad media, diferencias temporales, concentración de equipos y persistencia competitiva de los ciclistas.

2.2 Objetivos específicos

- Examinar la evolución temporal de la velocidad media de los ganadores.
- Comparar las diferencias temporales entre los primeros clasificados en los periodos 2007–2016 y 2017–2026.
- Describir cómo se distribuyen las posiciones del Top 10 entre los equipos participantes.
- Evaluar si haber obtenido previamente una posición en el Top 10 se asocia con repetir ese resultado en la siguiente participación.
- Explorar la relación entre la edad de los ciclistas y su velocidad media individual.

2.3 Hipótesis y preguntas de análisis

H1. La velocidad media de los ganadores presenta una tendencia creciente durante 2007–2026.

H2. Las brechas temporales entre los primeros clasificados difieren entre 2007–2016 y 2017–2026.

H3. Las posiciones del Top 10 muestran una distribución desigual entre los equipos participantes. Esta dimensión se aborda mediante indicadores descriptivos, sin atribuirle un contraste inferencial.

H4. Haber conseguido previamente una posición en el Top 10 se asocia positivamente con repetirla en la siguiente participación.

Además, se realizó un análisis complementario de edad y velocidad individual. Este análisis permite ampliar la descripción del rendimiento, pero sus resultados se interpretan separadamente de las cuatro hipótesis principales.

3. Alcance del estudio

El periodo seleccionado comprende veinte ediciones consecutivas del Tour de Francia masculino, desde 2007 hasta 2026. La unidad de análisis cambia según la pregunta: edición anual para la evolución de la velocidad de los ganadores; diferencias de tiempo entre clasificados para la comparación de décadas; posiciones finales y equipos para el análisis de concentración; y participaciones sucesivas de ciclistas para el estudio de persistencia.

Esta estructura exige no confundir los tamaños de muestra ni los niveles de observación. Una observación correspondiente a una edición no equivale a una observación individual de un corredor, y una posición del Top 10 no equivale a un equipo único. Por ello, cada apartado utiliza el conjunto de registros que corresponde a su indicador.

4. Obtención y procedencia de los datos

La investigación se apoyó en dos fuentes principales. En primer lugar, se utilizó el repositorio público LeTourDataSet, que ofrece archivos CSV históricos relativos a los corredores y a las etapas del Tour de Francia. En concreto, se trabajó con los archivos TDF_Riders_History.csv y TDF_Stages_History.csv, que proporcionan una base estructurada para las clasificaciones y los datos de las etapas.

En segundo lugar, se consultó ProCyclingStats (https://www.procyclingstats.com/) como fuente complementaria para contrastar información histórica de etapas y corredores. Durante el desarrollo del proyecto, la página no ofrecía una opción directa para descargar los conjuntos de datos completos que se necesitaban. Por este motivo, no fue posible resolver toda la extracción mediante una descarga masiva y fue necesario recopilar manualmente determinados datos consultados en las páginas históricas.

Una de las tareas que requirió mayor trabajo manual fue la obtención de las edades de los ciclistas. La información se consultó edición por edición y se copió año por año a una hoja de cálculo de Excel. Posteriormente, la tabla se revisó y organizó para convertirla en un conjunto de datos estructurado, que pudiera integrarse con el resto de las tablas y utilizarse en Python. Este procedimiento permitió disponer de la variable edad para el análisis individual, aunque implicó un esfuerzo adicional de transcripción y comprobación.

La recopilación manual se realizó con el objetivo de completar variables que no estaban disponibles de forma homogénea en los archivos iniciales. Excel funcionó como etapa intermedia de organización y control, mientras que los archivos estructurados finales se transformaron en datasets aptos para su lectura y tratamiento mediante pandas.

4.1 Fuentes principales

- LeTourDataSet – datos históricos de corredores y etapas: https://github.com/thomascamminady/LeTourDataSet/tree/master/data/men
- ProCyclingStats – consulta de resultados, etapas y datos históricos: https://www.procyclingstats.com/
- Excel – organización intermedia y estructuración de los registros de edad recopilados manualmente.

La documentación pública del repositorio LeTourDataSet describe archivos separados para resultados de corredores y etapas, con registros históricos del Tour masculino. La documentación de la biblioteca procyclingstats muestra que la información de la web puede consultarse y analizarse mediante herramientas de extracción de páginas; sin embargo, en este proyecto la disponibilidad de una descarga directa de los datasets completos no resolvió las necesidades concretas de recopilación.

5. Preparación, limpieza e integración

Una vez reunida la información, se inició una fase de inspección para conocer la estructura de los archivos, sus dimensiones, nombres de columnas, tipos de datos y cobertura temporal. Se revisaron los registros duplicados, los valores ausentes y las posibles inconsistencias antes de realizar los cálculos.

5.1 Delimitación temporal y depuración

Los registros se filtraron para conservar las ediciones comprendidas entre 2007 y 2026. La revisión incluyó la comprobación de que los años y las etapas estuvieran correctamente identificados y de que las variables numéricas pudieran utilizarse en las operaciones posteriores. También se examinaron anomalías puntuales en los registros de etapas.

En la edición de 2022 se detectaron cuatro registros asociados al número de etapa 1. Tras contrastar la información histórica, se conservó el registro correspondiente a la etapa de Copenhague, ganada por Yves Lampaert, y se excluyeron tres registros inconsistentes de la copia de trabajo. Esta decisión se tomó para evitar que datos duplicados o incorrectamente asociados afectaran los cálculos de distancia y rendimiento.

5.2 Tratamiento de valores ausentes

Se revisaron los valores nulos de las variables relevantes. En las columnas de bonificaciones y penalizaciones, los valores ausentes se interpretaron como ausencia de bonificación o penalización y se sustituyeron por cero en la copia utilizada para el análisis. Esta decisión se aplicó a esas variables concretas y no debe generalizarse a cualquier valor nulo, cuyo tratamiento depende del significado de cada campo.

5.3 Integración de tablas y variables derivadas

Los archivos de corredores y etapas se organizaron para relacionar los resultados finales de cada edición con la información de distancia correspondiente. La integración permitió calcular variables derivadas, entre ellas la distancia total, el tiempo total y la velocidad media individual. La velocidad se expresó en kilómetros por hora y se utilizó como indicador de rendimiento para las comparaciones temporales y los análisis complementarios.

La edad recopilada manualmente se incorporó como variable adicional después de organizar los registros en Excel y convertirlos en datasets. Antes de utilizarla, fue necesario comprobar que los años y los corredores quedaran asociados correctamente, ya que un error de correspondencia podría alterar los grupos de edad y los resultados del análisis.

5.4 Construcción de indicadores

- Velocidad media: relación entre distancia total y tiempo total de la edición o participación correspondiente.
- Brecha temporal: diferencia entre el tiempo del corredor de referencia y el de los demás clasificados, según el análisis.
- Concentración de equipos: recuento de posiciones del Top 10 atribuidas a cada equipo e índice HHI.
- Persistencia individual: comparación entre el resultado Top 10 de una participación y el de la participación posterior.
- Edad: variable incorporada a partir de la recopilación anual y estructuración en Excel y datasets.

6. Metodología de análisis

6.1 Análisis exploratorio

La primera fase tuvo como propósito comprender la estructura y el comportamiento de los datos antes de realizar contrastes estadísticos. Se calcularon medidas descriptivas, frecuencias, distribuciones y resúmenes por edición, corredor y equipo. Las visualizaciones se utilizaron para identificar tendencias, diferencias entre grupos y posibles observaciones atípicas.

El análisis exploratorio incluyó la evolución de la velocidad de los ganadores, las diferencias de tiempo entre clasificados, la presencia de equipos en el Top 10, la repetición de resultados destacados y la distribución de edades. También se exploraron variables de participación y rendimiento para identificar patrones que pudieran orientar la interpretación posterior.

6.2 Análisis inferencial

Para H1 se estimó una regresión lineal de la velocidad media de los ganadores respecto al año. Se utilizaron errores estándar HAC para contemplar posibles problemas de autocorrelación y heterocedasticidad en la serie temporal.

Para H2 se compararon las brechas temporales de los periodos 2007–2016 y 2017–2026. Se aplicaron la prueba t de Welch, que no requiere asumir igualdad de varianzas entre grupos, y la prueba U de Mann–Whitney como contraste no paramétrico. La interpretación conjunta permite valorar si las diferencias observadas cuentan con evidencia estadística.

H3 se analizó descriptivamente mediante el recuento de posiciones del Top 10 por equipo y el índice Herfindahl–Hirschman (HHI). Este indicador resume el grado de concentración de las posiciones entre los equipos. Dado el planteamiento adoptado, no se presenta como una hipótesis inferencial contrastada.

Para H4 se utilizó un modelo logístico estimado mediante GEE, adecuado para datos en los que un mismo ciclista puede aparecer en varias participaciones. El modelo evaluó la asociación entre haber conseguido previamente un Top 10 y repetir ese resultado, incorporando ajustes por año e intervalo entre participaciones.

6.3 Análisis complementario de edad

Se compararon descriptivamente las velocidades medias por grupos de edad y se estimó un modelo lineal mixto para examinar la asociación entre edad y velocidad individual, considerando la estructura de observaciones repetidas por ciclista y edición. Este análisis se presenta como complemento y no sustituye las cuatro hipótesis principales.

7. Resultados principales

7.1 H1. Evolución de la velocidad media de los ganadores

La regresión estimó un incremento de 0,1675 km/h por año. El valor p unilateral fue 0,000020 y el coeficiente de determinación R^2 fue 0,6134. Al ser el valor p inferior a 0,05, se rechaza la hipótesis nula y se encuentra evidencia estadística a favor de una tendencia creciente de la velocidad media de los ganadores durante el periodo.

El resultado describe una tendencia temporal, pero no demuestra que un único factor la haya causado. La velocidad puede depender de la configuración de los recorridos, el desnivel, las condiciones meteorológicas, las estrategias deportivas, la tecnología y otros elementos que no se incorporaron directamente en el modelo.

7.2 H2. Comparación de brechas temporales entre décadas

La prueba t de Welch obtuvo p = 0,522255 y la prueba U de Mann–Whitney p = 0,570750. Ambos valores superan el umbral de 0,05, por lo que no se rechaza la hipótesis nula. En consecuencia, no se encontró evidencia estadística suficiente para afirmar que las brechas temporales comparadas difieran entre 2007–2016 y 2017–2026.

Este resultado no significa que las brechas hayan sido idénticas en todas las ediciones, sino que las diferencias observadas en la muestra no fueron suficientemente concluyentes bajo las pruebas aplicadas.

7.3 H3. Distribución de equipos en el Top 10

Se contabilizaron 198 posiciones de las 200 previstas. Los tres equipos con mayor presencia reunieron el 15,66 % de las posiciones y los diez equipos con mayor representación acumularon el 33,33 %. El índice HHI fue 0,0199. En conjunto, estos valores describen una distribución desigual de las posiciones, con representación de varios equipos.

La interpretación de este apartado es descriptiva. Los indicadores permiten caracterizar la concentración observada, pero no justifican afirmar que las diferencias entre equipos sean estadísticamente significativas ni permiten explicar por sí solos las causas de esa distribución.

7.4 H4. Persistencia individual en el Top 10

Descriptivamente, los ciclistas que habían conseguido previamente un Top 10 presentaron una probabilidad de repetirlo del 45,24 %, frente al 4,29 % de quienes habían quedado fuera del Top 10 en la participación anterior. Sin embargo, el modelo GEE estimó un Odds Ratio de 2,1953, con p = 0,0775 e intervalo de confianza del 95 % [0,9171; 5,2551].

Como el valor p supera 0,05 y el intervalo incluye la unidad, no se encontró evidencia estadística suficiente para confirmar una asociación positiva significativa al nivel del 5 %. La diferencia descriptiva es relevante como patrón observado, pero debe distinguirse del resultado ajustado del modelo.

8. Resultados complementarios y discusión

8.1 Edad y velocidad individual

Las velocidades medias descriptivas fueron 39,529 km/h para el grupo de 19 a 24 años; 39,420 km/h para adultos jóvenes; 39,421 km/h para adultos; y 39,262 km/h para veteranos. Estas diferencias son pequeñas y no deben interpretarse de forma aislada.

El modelo lineal mixto, aplicado a 3.082 registros de 1.003 ciclistas y 20 ediciones, estimó un coeficiente de edad de −0,0025, con p = 0,3537 e intervalo de confianza del 95 % [−0,0079; 0,0028]. Por tanto, no se encontró una asociación estadísticamente significativa entre edad y velocidad individual en el modelo aplicado.

8.2 Interpretación conjunta

Los hallazgos muestran que las distintas dimensiones del rendimiento no evolucionan necesariamente de manera paralela. La velocidad media de los ganadores aumentó de forma estadísticamente significativa, mientras que las brechas temporales entre los primeros clasificados no presentaron diferencias significativas entre las décadas comparadas. Por ello, un incremento en la velocidad media no implica necesariamente una mayor o menor separación entre los principales corredores.

En el ámbito colectivo, la distribución de posiciones del Top 10 muestra que ciertos equipos acumulan una mayor representación. No obstante, el análisis es descriptivo y no permite establecer por sí mismo qué factores explican la presencia de esos equipos. En el ámbito individual, la repetición de un Top 10 fue más frecuente entre quienes ya habían logrado ese resultado, aunque el modelo GEE no confirmó la asociación con significación estadística al 5 %.

El análisis complementario de edad tampoco encontró evidencia estadística suficiente de asociación con la velocidad individual. En conjunto, los resultados aconsejan utilizar varios indicadores para estudiar el rendimiento y evitar conclusiones generales a partir de una única medida.

9. Limitaciones

La investigación se limita al periodo 2007–2026 y depende de la disponibilidad y consistencia de los registros históricos. La recopilación manual de edades, aunque permitió completar la variable, implicó tareas de transcripción y comprobación susceptibles de errores humanos. Asimismo, la ausencia de una descarga directa de datasets completos desde ProCyclingStats obligó a complementar la información mediante consulta manual y estructuración propia.

En el análisis de concentración se identificaron dos posiciones faltantes respecto de las 200 previstas. Los cambios de denominación y patrocinio también dificultan el seguimiento de la continuidad de algunos equipos. Además, la velocidad y la regularidad competitiva pueden estar condicionadas por factores no incorporados directamente, como recorrido, desnivel, clima, estrategias y tecnología. Finalmente, el carácter observacional del estudio permite identificar tendencias y asociaciones, pero no establecer relaciones causales.

10. Recomendaciones y futuras líneas de investigación

Se recomienda ampliar el periodo de estudio para comparar la evolución del rendimiento en etapas históricas más extensas del ciclismo profesional. También sería conveniente incorporar variables relacionadas con los recorridos, como distancia, desnivel acumulado y condiciones meteorológicas, con el propósito de profundizar en los factores asociados a la evolución de la velocidad media.

Asimismo, futuras investigaciones podrían ampliar el análisis de concentración de equipos y persistencia individual mediante indicadores adicionales de continuidad y regularidad. Sería pertinente aplicar modelos que consideren la dependencia temporal y las participaciones repetidas de los corredores, así como desarrollar procedimientos reproducibles para recopilar y actualizar variables como edad y características de las etapas.

11. Conclusiones

- Durante 2007–2026, la velocidad media de los ganadores presentó una tendencia creciente estadísticamente significativa, estimada en 0,1675 km/h por año.
- No se encontraron diferencias estadísticamente significativas en las brechas temporales comparadas entre 2007–2016 y 2017–2026.
- Las posiciones del Top 10 mostraron una distribución desigual entre equipos; los diez equipos con mayor presencia reunieron el 33,33 % de las 198 posiciones contabilizadas. Este hallazgo es descriptivo.
- La repetición de un Top 10 fue más frecuente descriptivamente entre ciclistas con un Top 10 previo, pero el modelo GEE no confirmó una asociación significativa al nivel del 5 %.
- El análisis complementario no encontró una asociación estadísticamente significativa entre edad y velocidad media individual.

En conjunto, la evolución del rendimiento en el Tour de Francia no puede resumirse mediante un único indicador. Los resultados muestran una tendencia en la velocidad de los ganadores, mientras que las brechas temporales, la distribución por equipos y la persistencia individual presentan comportamientos y niveles de evidencia diferentes.

12. Herramientas y documentación

El proyecto se desarrolló en Python mediante notebooks para la obtención, limpieza, integración, exploración y análisis estadístico. Se utilizaron bibliotecas de análisis y modelización como pandas, NumPy y statsmodels, además de herramientas de visualización. Excel se empleó como herramienta intermedia para recopilar, ordenar y estructurar las edades por edición antes de convertir los registros en datasets.

Los principales materiales de trabajo son el notebook de análisis exploratorio (main.ipynb) y el notebook de análisis inferencial (analisis_inferencial.ipynb). Las fuentes de datos principales son LeTourDataSet y ProCyclingStats. La documentación de la biblioteca procyclingstats describe métodos para consultar y analizar páginas históricas de carreras y etapas; el repositorio LeTourDataSet proporciona archivos CSV históricos de corredores y etapas.

Referencias y recursos

LeTourDataSet. (s. f.). *Every cyclist and stage of the Tour de France*. GitHub. https://github.com/thomascamminady/LeTourDataSet

ProCyclingStats. (s. f.). *ProCyclingStats*. https://www.procyclingstats.com/

procyclingstats. (s. f.). *Documentation*. https://procyclingstats.readthedocs.io/en/latest/

Nota: antes de la entrega, conviene completar las fechas de consulta y cualquier referencia específica de páginas históricas efectivamente utilizadas.